

Wie können neuronale Netzwerke effizienter trainiert werden?

Maturaarbeit von Lukas Florian Münzel, 4P, Gymnasium Bäumlhof, 2022

Motivation

Künstliche neuronale Netzwerke werden heutzutage von der Empfehlung von YouTube-Videos bis zur Früherkennung von Brustkrebs eingesetzt [1, 2]. Zum Trainieren dieser neuronaler Netzwerke werden siebenstellige Beträge ausgegeben, da dieser Prozess derartig rechenintensiv ist. Dieses Trainieren ist vergleichbar mit dem Lernprozess bei einem Kleinkind, beispielsweise beim Erlernen des Erkennens von Katzen und Hunden.

Da dieser Trainingsprozess derartig ressourcenintensiv ist, versuchen wir einen Teil dieses Trainingsprozesses bedeutend effizienter und präziser zu machen.




Abbildung 1: Schema eines künstlichen neuronalen Netzwerks

Methoden

Um festzustellen, wie gut das neuronale Netzwerk zu einem gegebenen Zeitpunkt seine Aufgabe erfüllt, wird der sogenannte Verlust berechnet. Der Verlust misst, wie stark sich die Ausgaben der Neuronen der letzten Schicht von den für sie erwünschten Werten unterscheiden. Die Gewichte zwischen den verschiedenen Schichten werden anschliessend so angepasst, dass dieser Verlust minimiert wird. In Abbildung 1 sind die Neuronen als Kreise dargestellt, die Verbindungen zwischen Neuronen stellen die Gewichte dar und die gezeigten Spalten von Neuronen werden jeweils als Schicht bezeichnet. Die Eigenschaftsfunktionen sind die Funktionen, welche die Ausgaben der vorletzten Neuronenschicht mit den Eingaben in die erste Schicht als Argument berechnen.

Unser Ansatz zieht zudem Informationen der Neuronen der vorletzten Schicht in Betracht. Genauer subtrahieren wir ein Mass der Informationsunabhängigkeit zwischen den Eigenschaftsfunktionen vom Verlust. Da das neuronale Netzwerk versucht, den Verlust zu minimieren, wird dieses Informationsunabhängigkeitsmass, welches im Folgenden als Kovarianzmass bezeichnet wird, maximiert. Wenn dieses Kovarianzmass eins ist, können die optimalen Gewichte zwischen der vorletzten und der letzten Neuronenschicht äusserst effizient berechnet werden. Dies ist analog dazu, dass die Projektion auf die lineare Hülle einer Menge von Vektoren einfach als die Summe der Projektionen auf die einzelnen Vektoren dargestellt werden kann, wenn diese Vektoren orthogonal zueinander sind (siehe Abbildungen 2 und 3).




Abbildung 2: Projektion auf die lineare Hülle von nicht orthogonalen Vektoren




Abbildung 3: Projektion auf die lineare Hülle von orthogonalen Vektoren

Resultate und Diskussion




Abbildung 4: Das Kovarianzmass für verschiedene Anzahl an Eigenschaftsfunktionen

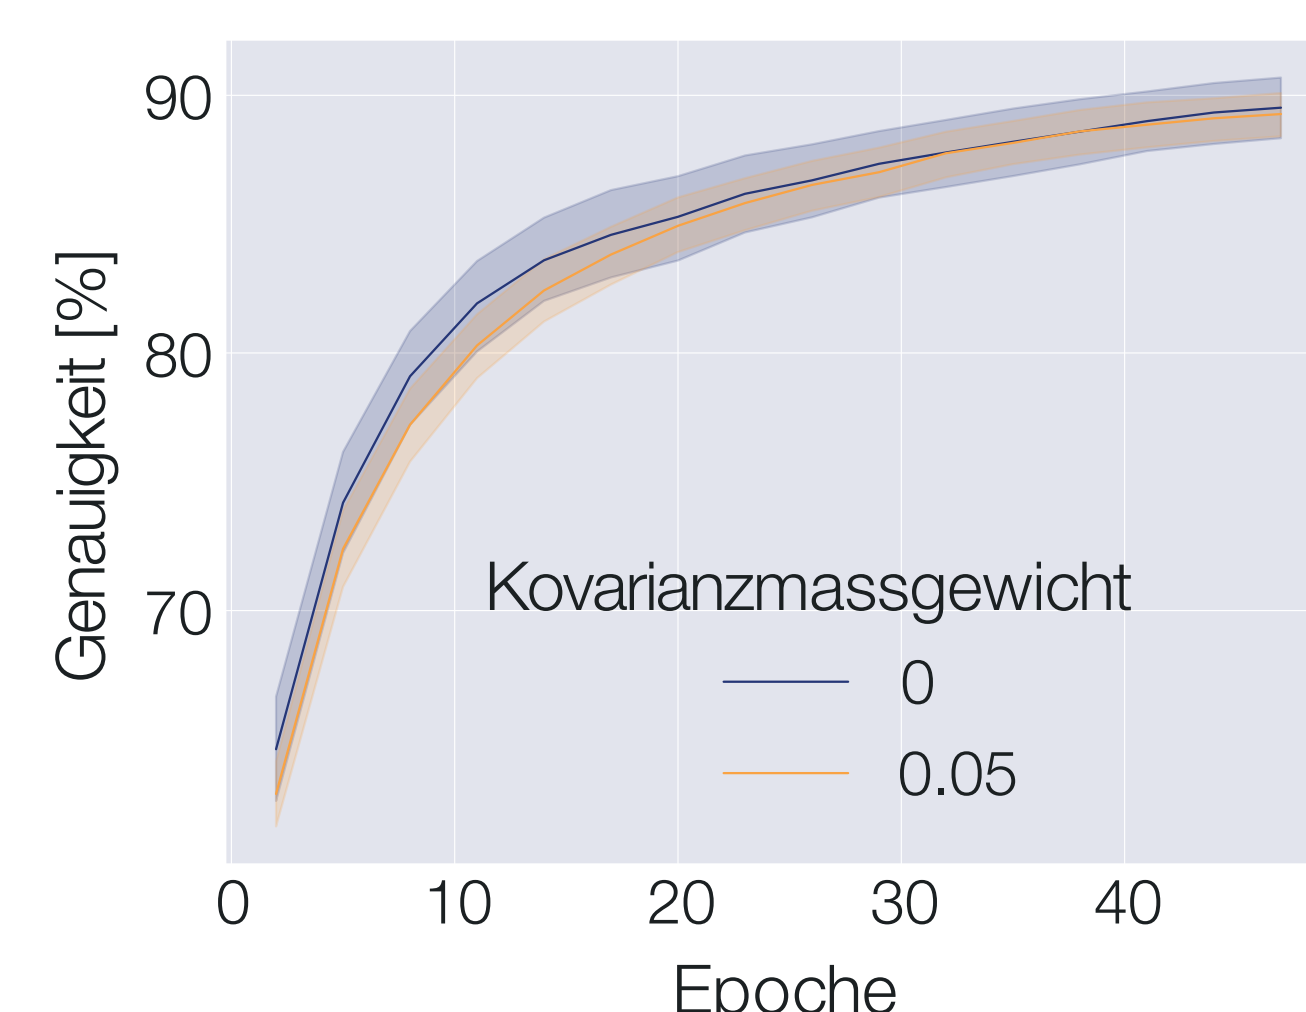


Abbildung 5: Entwicklung der Genauigkeit während des Trainingsprozesses




Abbildung 6: Entwicklung des Kovarianzmasses während des Trainingsprozesses

Es war uns möglich, nahezu orthogonale Eigenschaftsfunktionen zu generieren, ohne dass das neuronale Netzwerk schlechtere Vorhersagen machte, wie in Abbildungen 5 und 6 erkenntlich ist. Hierbei bedeutet ein positives Kovarianzmassgewicht, dass beim jeweiligen Trainingsprozess zur Orthogonalisierung der Eigenschaftsfunktionen das Kovarianzmass vom Verlust subtrahiert wurde.

Zudem zeigten wir, dass die Eigenschaftsfunktionen bei komplexeren Problemen orthogonaler zueinander sind, wie beispielhaft in Abbildung 4 gezeigt. Unsere Hypothese für diese positive Korrelation ist, dass bei komplexeren Problemen weniger Information zwischen den Eigenschaftsfunktionen redundant sein darf. Dies hat zur Konsequenz, dass die Eigenschaftsfunktionen orthogonaler zueinander sind.

Ausblick

Ein erster Schritt, um unsere Methodik auf den Prüfstand zu stellen, wäre es, zu versuchen, unsere Resultate mit komplexeren Datensets wie beispielsweise MNIST [3] zu replizieren. MNIST ist ein Standardproblem des maschinellen Lernens, bei dem ein neuronales Netzwerk handgeschriebene Ziffern erkennen soll.

Bei orthogonalen Eigenschaftsfunktionen kann eine neue Klasse äusserst effizient optimal vorhergesagt werden. Dementsprechend wäre es ein sinnvoller nächster Schritt, zu versuchen, dieses effizientere Verfahren praktisch mit den nahezu orthogonalen Eigenschaftsfunktionen anzuwenden.

Quellen

- [1] Ioannis Sechopoulos, Jonas Teuwen, and Ritse Mann. Artificial intelligence for breast cancer detection in mammography and digital breast tomosynthesis: State of the art. Seminars in Cancer Biology, 72:214–225, 2021. Precision Medicine in Breast Cancer.
- [2] Paul Covington, Jay Adams, and Emre Sargin. Deep neural networks for youtube recommendations. In Proceedings of the 10th ACM Conference on Recommender Systems, New York, NY, USA, 2016.
- [3] Yann LeCun and Corinna Cortes. MNIST handwritten digit database. 2010.